

자전거 대여 수 예측 모델링 보고서

정재문

1. 가설 설정

- 기온이 높을수록 자전거 대여량은 증가할 것이다.
- 습도가 지나치게 높거나 낮으면 대여량은 감소할 것이다.
- 날씨에 따라(특히 화창·구름) 대여량이 높을 것이다.

2. 분석의 전개

(1) 데이터 탐색 (EDA)

- 데이터 구성: 날짜, 시간, 기온, 체감온도, 습도, 풍속, 날씨 상황 등과 대여량(count)
- EDA 결과:
 - 요일·시간대별로 대여량의 뚜렷한 차이가 나타남
 - 기온과 대여량 사이에 양의 상관관계 존재
 - 습도가 높을수록 대여량 감소 경향

(2) 데이터 전처리

- 결측치 및 이상치 제거
- 로그 변환(count_log)으로 분포를 안정화 → RMSLE 기반 모델링 적합
- 파생 변수 생성 (예: 계절, 휴일, 시간대 구분 등)

(3) 모델링 및 성능 비교

- Baseline: Linear Regression
- 다양한 모델 학습: Ridge, Lasso, ElasticNet, Polynomial Regression(2 차·3 차)
- 성능 지표: MAE, RMSLE, R^2
- 결과 요약

model	MAE	MSE	RMSE	RMSLE	R2
LinearRegression	105.679681	2.510486e+04	158.445129	1.008330	0.220750
Ridge	105.677467	2.510292e+04	158.438996	1.008330	0.220811
Lasso	140.111572	4.065799e+04	201.638259	1.414367	-0.262016
ElasticNet	105.598830	2.500977e+04	158.144764	1.008727	0.223702
Polynomial_2nd	75.976335	1.494799e+04	122.261984	0.870094	0.536017
Polynomial_3rd	2121.651434	9.271702e+09	96289.675958	0.908035	-287790.73

3. 인사이트

- 날씨: 날씨가 좋을수록 대여 증가 → 팽팽, 흐림에 수요 피크

- 습도: 높으면 대여량 급감 → 쾌적한 날씨 (40~80%)일수록 수요 ↑
 - 시간대/요일: 출퇴근 시간과 평일에 집중 → “생활형 자전거 수요” 강함
 - 실무적 적용 가능성:
 - 날씨 예보 기반으로 대여소 자전거 수량을 조정
 - 주중 출퇴근 시간대에는 대여소 보급 강화 필요
 - 특정 계절·날씨 조건에서 마케팅 전략 가능
-

4. 결론 및 제언

- 가설 대부분이 데이터로 검증됨: 기온, 습도, 시간대가 핵심 요인
- Polynomial Regression(2 차)이 가장 안정적 예측력을 보임 (예시)
- 향후 과제:
 - 장마, 행사 등 외부 요인 반영
 - 딥러닝 기반 시계열 모델 적용
 - 실시간 운영 시스템과의 연계

분석을 로그변환 후에 수행한 이유.

1. 로그 변환이 필요한 이유

원래 데이터를 그대로 쓰면 모델은 큰 값에만 맞춰 학습하고 작은 값은 무시한다.

RMSLE 는 지표 계산 시 자동으로 로그를 취하기 때문에, **학습 데이터도 로그 변환을 해야 평가 기준과 학습 기준이 일치한다.**

로그 변환을 적용하면 작은 값과 큰 값을 같은 스케일에서 다룰 수 있어 안정적인 학습이 가능하다.

2. 간단한 예시

(A) 원래 값 그대로 학습

- 실제: [1, 10, 1000]
- 예측: [2, 12, 900]
- RMSE ≈ 57.7
- RMSLE ≈ 0.26

👉 큰 값(1000)의 오차가 RMSE 를 압도 → 학습 기준과 평가 기준 불일치

(B) 로그 변환 후 학습

- 실제(log): [0.693, 2.398, 6.908]
- 예측(log): [1.099, 2.565, 6.802]
- RMSE ≈ 0.148
- RMSLE ≈ 0.148

👉 학습과 평가가 같은 로그 공간에서 진행 → 안정적

3. RMSE·MAE 도 로그 변환할까?

- 원래 RMSE/MAE: 절대 오차 기준 → 큰 값 차이를 크게 본다.
- 로그 변환 RMSE/MAE: 상대 오차(%) 기준 → 작은 값의 비율 차이를 크게 본다.

예시)

- 실제 10 vs 20 → 차이 10 (100% 증가)
- 실제 1000 vs 1010 → 차이 10 (1% 증가)

👉 원래 RMSE/MAE: 둘 다 같은 “10 차이”로 평가

👉 로그 변환 RMSE/MAE: 100% vs 1% → 전자가 훨씬 크다고 평가

4. 언제 어떤 걸 써야 할까?

상황	적합한 방식	이유
큰 값의 절대 오차가 중요한 경우 (집값, 전력 사용량, 매출액 예측 등)	원래 값 + RMSE/MAE	실제 손실이 절대 금액 기준으로 발생
상대적인 비율 차이가 중요한 경우 (수요 예측, 주문량 예측, 개수 단위 데이터 등)	로그 변환 + RMSE/MAE ($\approx$ RMSLE)	작은 값도 공정하게 반영, 큰 값 치중 방지
데이터 분포가 크고 치우친 경우	로그 변환 + RMSLE	평가와 학습 기준 일치, 안정적 학습 가능

5. 핵심 요약

- RMSE/MAE 는 절대 오차 기준
- **로그 변환 RMSE/MAE (또는 RMSLE)**는 상대적 오차 기준
- 상황에 맞춰 선택해야 하고, RMSLE 를 쓸 땐 학습 데이터도 반드시 로그 변환해야 안정적이다