



보고서: 포르투갈 은행 마케팅 데이터 분석

정재문

1. 문제 정의

본 프로젝트의 목표는 은행 고객이 정기 예금에 가입할지 여부(y)를 예측하는 분류 모델을 구축하는 것. 이를 통해 은행은 마케팅 효율성을 높이고, 불필요한 비용(콜센터 리소스, 인건비 등)을 절감할 수 있다.

- 문제 유형: 이진 분류(Binary Classification)
- 주요 성능 지표: Accuracy, Precision, Recall, F1-score
 - Accuracy → 전체 중에서 맞춘 비율 직관적, 불균형 데이터에 취약
 - Precision → 예측한 양성 중에서 맞춘 비율 불필요한 긍정 줄임, 진짜 양성 놓칠 수 있음
 - Recall → 실제 양성 중에서 맞춘 비율 놓치는 경우 줄임, 잘못된 긍정 많아질 수 있음
 - F1-score → Precision 과 Recall 의 균형 불균형 데이터에서 유용, 특정 지표만 중요할 땐 부족
- 최종 활용: 고객 타겟팅 전략 수립 및 마케팅 ROI (투자로부터 얻은 이익 대비 투자 비용의 비율) 향상

2. 데이터 설명 & 전처리 과정

데이터 개요

- 출처: 포르투갈 은행 마케팅 캠페인 (2008-2010)
- 파일명: bank-additional-full.csv
- 타겟 변수: 고객의 정기 예금 가입 여부 (y: yes / no)

주요 변수

- 개인 특성: age, job, marital, education, housing, loan
- 캠페인 특성: contact, month, day_of_week, campaign(연락 횟수), previous, poutcome(이전 캠페인 결과)
- 경제 지표: emp.var.rate(고용률), cons.price.idx(물가지수), euribor3m(금리), nr.employed(고용자 수)

전처리 과정

1. 결측치 처리

- unknown 값을 결측치로 간주 후 처리
- pdays=999 → “이전 캠페인 접촉 없음”을 의미하는 새로운 변수(prev_contact) 생성

2. 변수 제거

- duration: 통화 시간은 예측 시 누수(leakage) 가능성이 높아 제외

3. 인코딩

- 범주형 변수 → 원-핫 인코딩 (job, marital, education 등)

4. 데이터 분할

- 학습 데이터 (Train) / 검증 데이터 (Test) 분리

3. 탐색적 분석 결과 (EDA)

EDA를 통해 가입 여부와 변수 간의 관계를 시각적으로 확인하였다.

- **직업(job)별 가입률**
→ 학생·은퇴자 그룹에서 가입률이 높고, 블루칼라·자영업자는 낮음
- **교육 수준(education)**
→ 고등 교육 이상에서 가입률이 상대적으로 높음
- **월(month)**
→ 5월(May), 8월(August) 등 특정 시기에 가입률 상승
- **경제 지표**
 - 낮은 euribor3m 금리 시 가입률 ↑
 - 소비자 신뢰지수(cons.conf.idx)가 높을수록 가입률 ↑

(🇮🇹 실제 분석 결과 그래프: 직업별 가입률 barplot, 월별 가입률 lineplot, 경제지표 vs 가입률 scatterplot 포함)

4. 모델별 성능 비교

다양한 분류 모델을 적용하고 성능을 비교하였다.

◆ 전체 모델 성능 요약

Model	Accuracy	Precision	Recall	F1 Score
Decision Tree	0.83	0.32	0.35	0.33
Random Forest	0.89	0.57	0.31	0.40
Bagging	0.88	0.52	0.30	0.38
AdaBoost	0.90	0.73	0.20	0.31
XGBoost	0.83	0.37	0.58	0.45
Voting	0.89	0.56	0.30	0.39
Stacking	0.89	0.64	0.26	0.37

◆ 모델링 4

Model	Accuracy	Precision	Recall	F1 Score
XGBoost	0.83	0.37	0.58	0.45
LightGBM	0.90	0.64	0.29	0.40
CatBoost	0.90	0.66	0.26	0.38

◆ 모델링 5

Model	Accuracy	Precision	Recall	F1 Score
XGBoost	0.83	0.37	0.58	0.45
LightGBM	0.90	0.63	0.28	0.39
CatBoost	0.90	0.66	0.27	0.39

5. 최종 전략 제시 (Precision vs Recall 기준)

- Precision 중심 전략
 - 목표: 불필요한 고객 접촉 최소화
 - 적합: 콜센터 리소스가 제한적일 때
 - 추천 모델: ADABOOST (False Positive 최소화)
- Recall 중심 전략
 - 목표: 모든 잠재 고객을 놓치지 않음
 - 적합: 인건비보다 가입자 확보가 중요한 경우

- 추천 모델: XGBoost (True Positive 극대화)

👉 따라서, 비즈니스 상황에 따라 Precision 또는 Recall 을 기준으로 모델 선택하는 유연한 접근이 필요하다.

6. 결론 및 제안

- 결론

- 데이터 분석 결과, 직업·교육 수준·경제 지표가 중요한 요인으로 확인
- 모델 성능 비교에서 XGBoost > Random Forest > Decision Tree > ADABOOST 순으로 우수
- Precision 과 Recall 은 trade-off 관계이므로, [상황별 전략적 선택](#)이 필요

- 제안

1. 콜센터 리소스 한정 시 → Precision 높은 Random Forest 활용
2. 고객 확보 최우선 시 → Recall 높은 XGBoost 활용
3. 향후 데이터 축적 시, 경제 지표 반영한 실시간 예측 모델 (KPI) 개발 고려
4. 고객 세분화(Segmentation) 기반의 맞춤형 마케팅 캠페인 추진